

KEYLA'S PORTOFOLIO

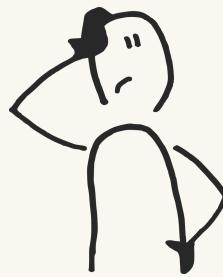
# Lung Cancer Prediction

NAME

Keyla Faristha Rindani

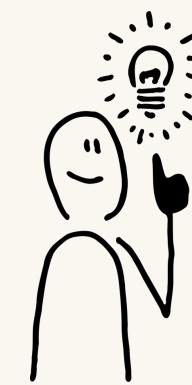
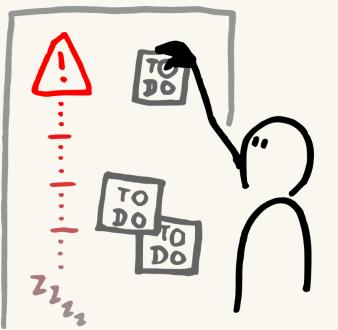
## INTRODUCTION

# Project Overview



## Problem

Mendeteksi penyakit paru-paru sejak dini itu sangat penting, tapi di banyak kasus, gejala awal tidak jelas. Banyak pasien baru terdeteksi setelah kondisinya parah. Untuk itu, dibutuhkan model prediksi yang bisa membantu mengidentifikasi potensi penyakit paru-paru lebih cepat berdasarkan data kesehatan pasien.



## Solution

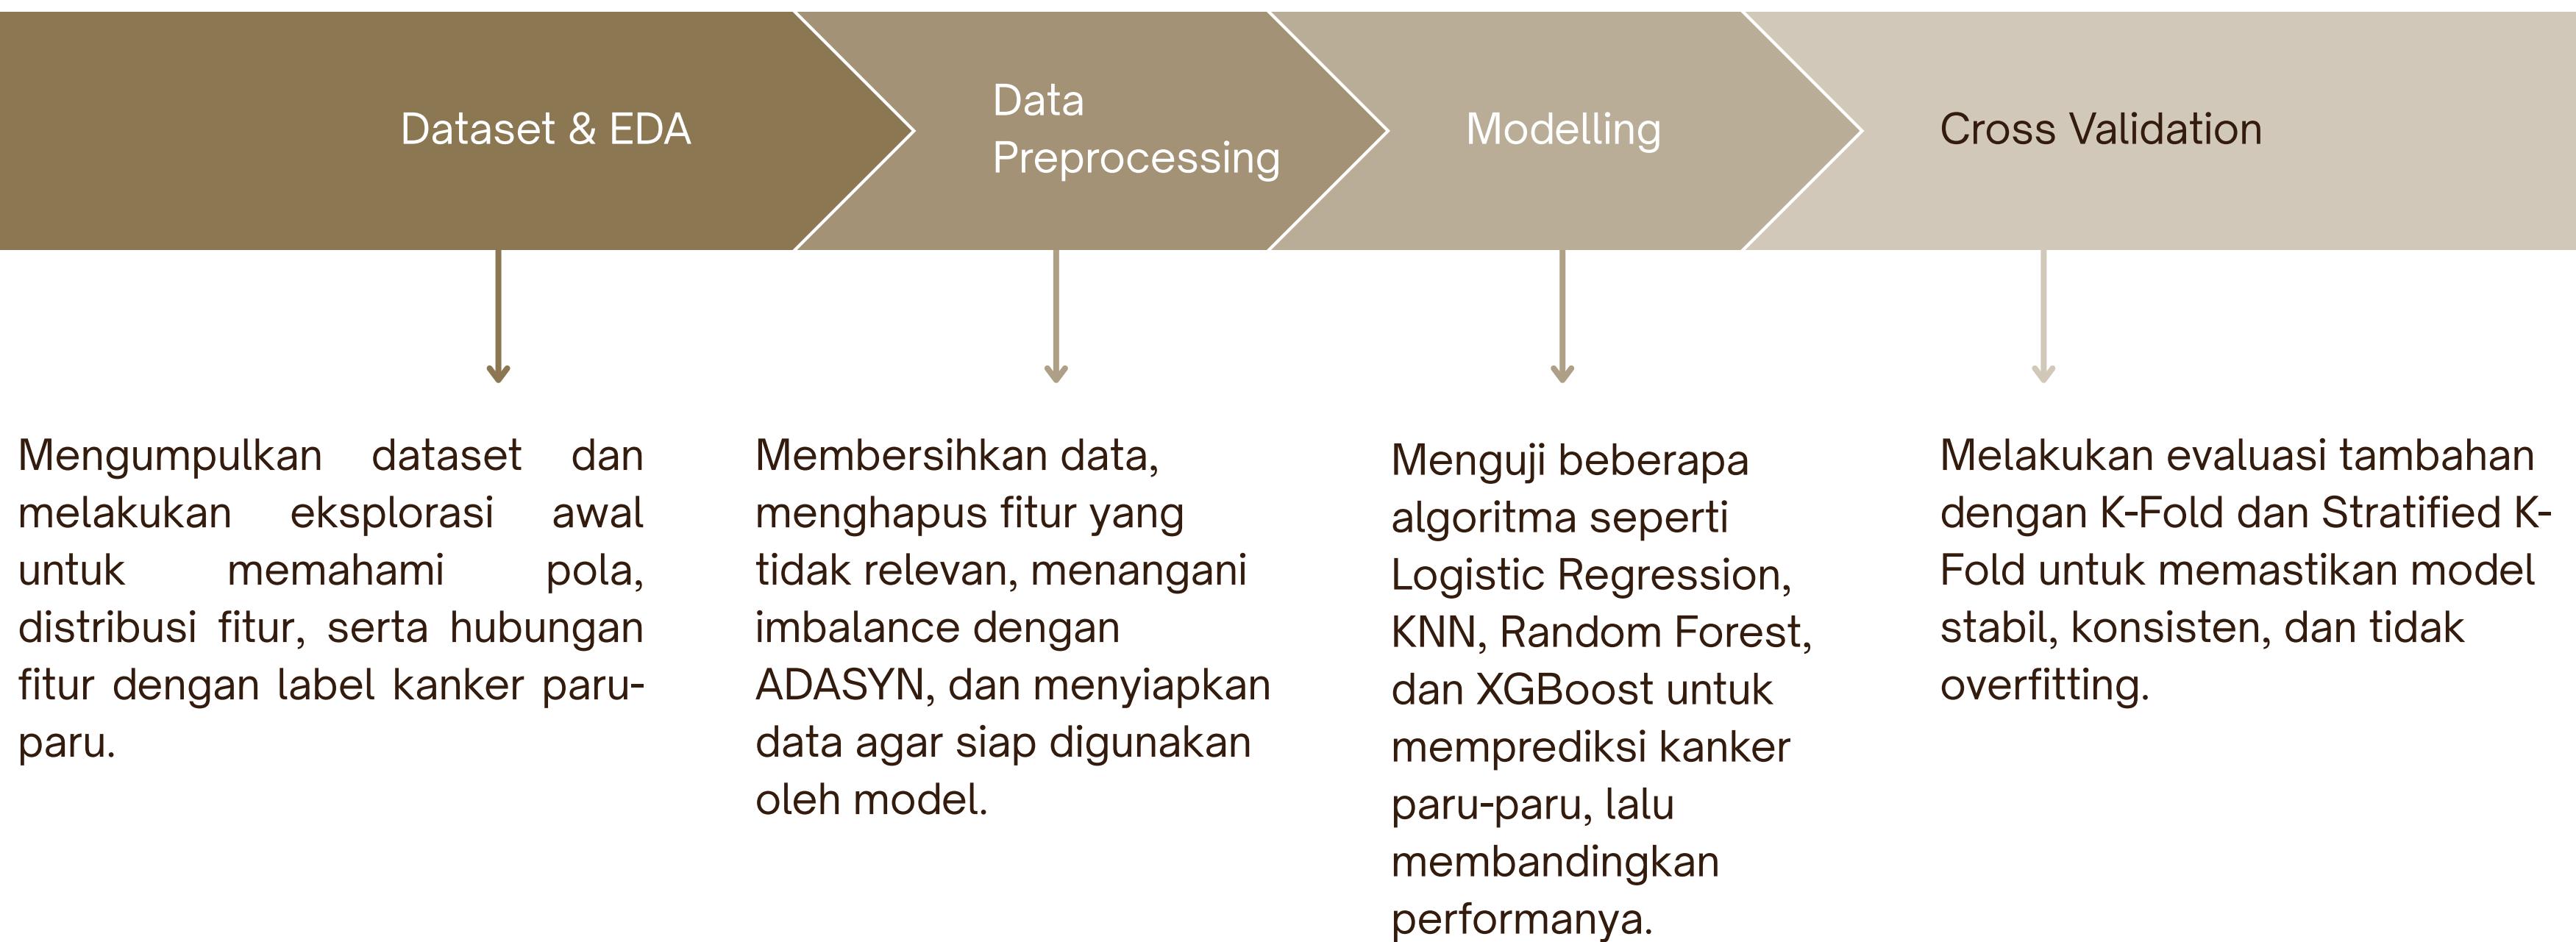
Saya membangun beberapa model machine learning (XGBoost, Random Forest, Logistic Regression, KNN) untuk memprediksi potensi penyakit paru-paru, lalu memilih model dengan akurasi terbaik.

## Why It Matters

Prediksi dini dapat membantu tenaga medis mengambil tindakan lebih cepat, meningkatkan peluang pasien mendapatkan penanganan yang tepat waktu.

## WORKFLOW

# Workflow



# Dataset

Sumber: Dataset publik dari kaggle

Jumlah Data: 309 dengan 16 kolom

Isi Fitur: Gender, Age, Smoking, Yellow Fingers, Anxiety, Peer Pressure, Chronic Disease, Fatigue, Allergy, Wheezing, Alcohol Consuming, Coughing, Shortness of Breath, Swallowing Difficulty, Chest Pain, Lung Cancer

Insight Awal:

- Ada beberapa fitur numerik dan kategorikal

# Fitur-fitur

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 309 entries, 0 to 308
Data columns (total 16 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   GENDER          309 non-null    object 
 1   AGE              309 non-null    int64  
 2   SMOKING          309 non-null    int64  
 3   YELLOW_FINGERS  309 non-null    int64  
 4   ANXIETY          309 non-null    int64  
 5   PEER_PRESSURE    309 non-null    int64  
 6   CHRONIC_DISEASE  309 non-null    int64  
 7   FATIGUE          309 non-null    int64  
 8   ALLERGY          309 non-null    int64  
 9   WHEEZING         309 non-null    int64  
 10  ALCOHOL_CONSUMING 309 non-null    int64  
 11  COUGHING        309 non-null    int64  
 12  SHORTNESS_OF_BREATH 309 non-null    int64  
 13  SWALLOWING_DIFFICULTY 309 non-null    int64  
 14  CHEST_PAIN       309 non-null    int64  
 15  LUNG_CANCER      309 non-null    object 
dtypes: int64(14), object(2)
memory usage: 38.8+ KB
```

# EDA (Exploratory Data Analysis)

## Mengecek Missing Value & Duplikat

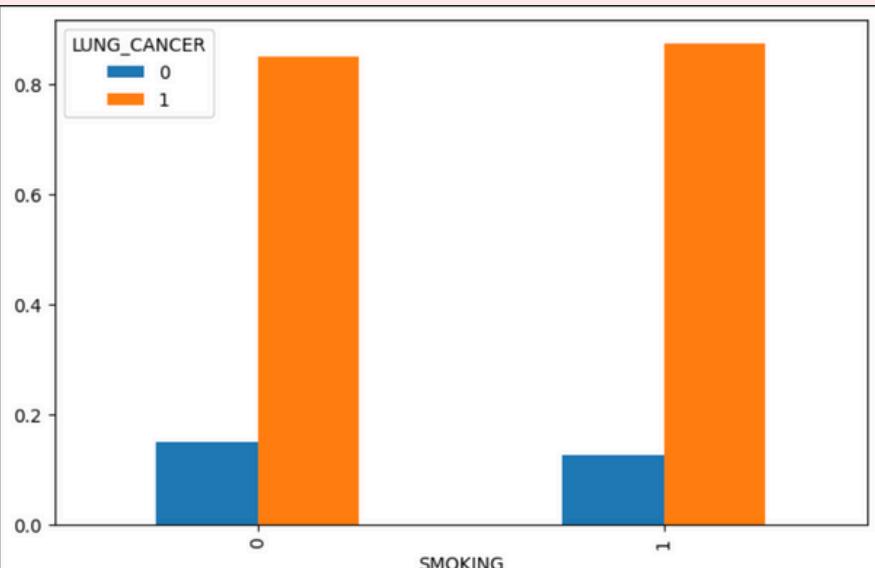
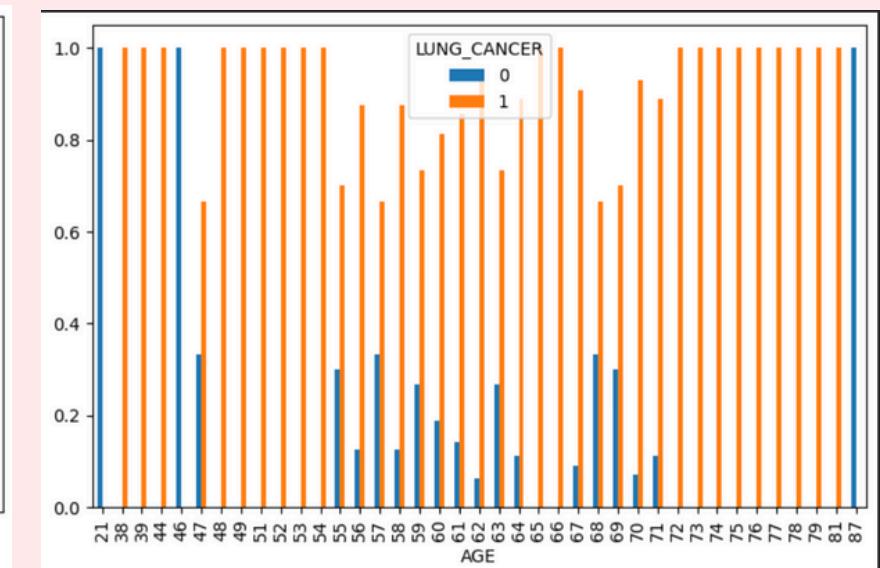
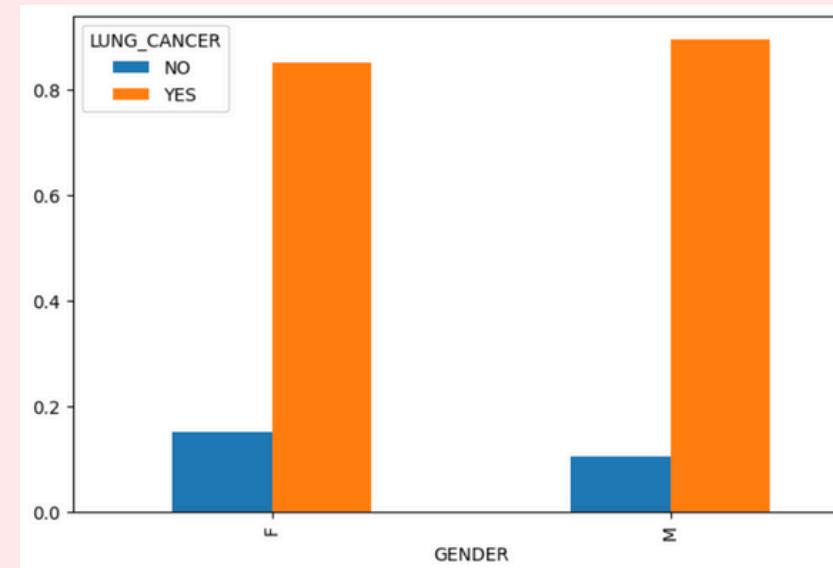
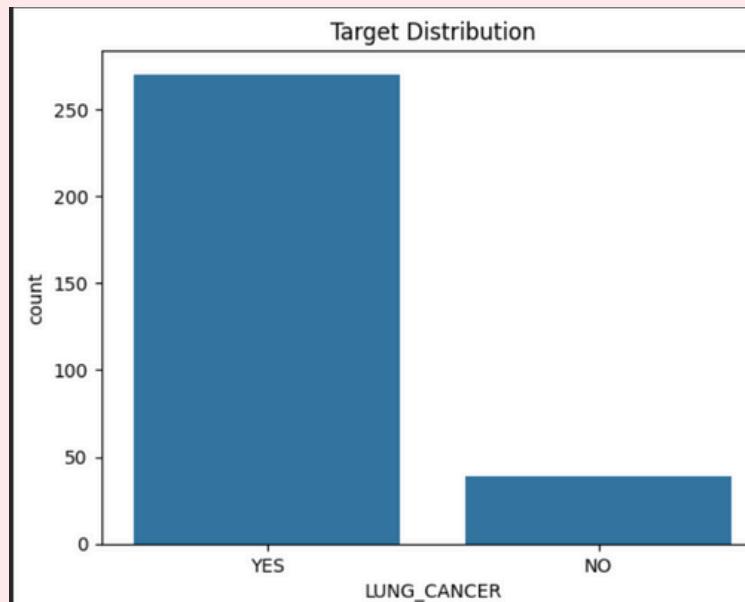
|                       | Missing Values | Missing Percentage | Data Type |
|-----------------------|----------------|--------------------|-----------|
| GENDER                | 0              | 0.0                | object    |
| AGE                   | 0              | 0.0                | int64     |
| SMOKING               | 0              | 0.0                | int64     |
| YELLOW_FINGERS        | 0              | 0.0                | int64     |
| ANXIETY               | 0              | 0.0                | int64     |
| PEER_PRESSURE         | 0              | 0.0                | int64     |
| CHRONIC_DISEASE       | 0              | 0.0                | int64     |
| FATIGUE               | 0              | 0.0                | int64     |
| ALLERGY               | 0              | 0.0                | int64     |
| WHEEZING              | 0              | 0.0                | int64     |
| ALCOHOL_CONSUMING     | 0              | 0.0                | int64     |
| COUGHING              | 0              | 0.0                | int64     |
| SHORTNESS_OF_BREATH   | 0              | 0.0                | int64     |
| SWALLOWING_DIFFICULTY | 0              | 0.0                | int64     |
| CHEST_PAIN            | 0              | 0.0                | int64     |
| LUNG_CANCER           | 0              | 0.0                | object    |

```
#Checking for Duplicates  
df.duplicated().sum()  
np.int64(33)
```

## Mengecek Konsisten Data

|     | GENDER | AGE | SMOKING | YELLOW_FINGERS | ANXIETY | PEER_PRESSURE | CHRONIC_DISEASE | FATIGUE | ALLERGY | WHEEZING | ALCOHOL_CONSUMING | COUGHING | SHORTNESS_OF_BREATH | SWALLOWING_DIFFICULTY | CHEST_PAIN | LUNG_CANCER |
|-----|--------|-----|---------|----------------|---------|---------------|-----------------|---------|---------|----------|-------------------|----------|---------------------|-----------------------|------------|-------------|
| 0   | M      | 69  | 1       | 2              | 2       | 1             | 1               | 2       | 1       | 2        | 2                 | 2        | 2                   | 2                     | 2          | YES         |
| 1   | M      | 74  | 2       | 1              | 1       | 1             | 2               | 2       | 2       | 1        | 1                 | 1        | 2                   | 2                     | 2          | YES         |
| 2   | F      | 59  | 1       | 1              | 1       | 2             | 1               | 2       | 1       | 2        | 1                 | 2        | 2                   | 1                     | 2          | NO          |
| 3   | M      | 63  | 2       | 2              | 2       | 1             | 1               | 1       | 1       | 1        | 1                 | 1        | 2                   | 1                     | 2          | NO          |
| 4   | F      | 63  | 1       | 2              | 1       | 1             | 1               | 1       | 1       | 1        | 2                 | 1        | 2                   | 2                     | 1          | NO          |
| ... | ...    | ... | ...     | ...            | ...     | ...           | ...             | ...     | ...     | ...      | ...               | ...      | ...                 | ...                   | ...        | ...         |
| 304 | F      | 56  | 1       | 1              | 1       | 2             | 2               | 2       | 1       | 1        | 2                 | 2        | 2                   | 2                     | 1          | YES         |
| 305 | M      | 70  | 2       | 1              | 1       | 1             | 1               | 2       | 2       | 2        | 2                 | 2        | 2                   | 2                     | 1          | YES         |
| 306 | M      | 58  | 2       | 1              | 1       | 1             | 1               | 1       | 1       | 2        | 2                 | 2        | 2                   | 1                     | 1          | YES         |
| 307 | M      | 67  | 2       | 1              | 2       | 1             | 1               | 2       | 2       | 1        | 2                 | 2        | 2                   | 1                     | 2          | YES         |
| 308 | M      | 62  | 1       | 1              | 1       | 2             | 1               | 2       | 2       | 2        | 2                 | 2        | 1                   | 1                     | 2          | YES         |

## Visualisasi Fitur Target & Fitur Numerikal



# Data Preprocessing

Menghapus data duplikat

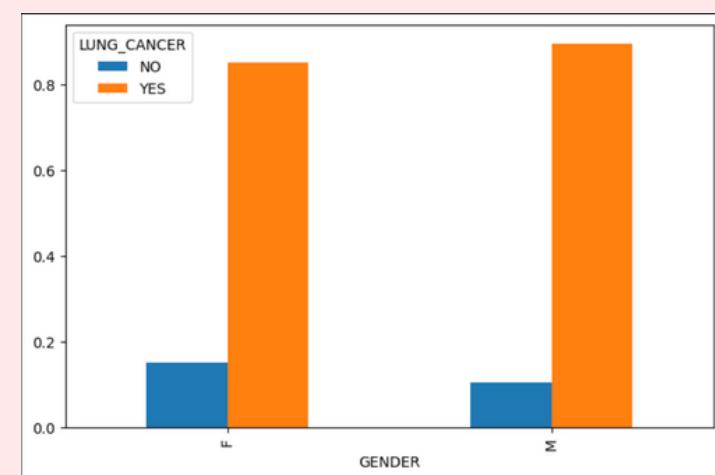
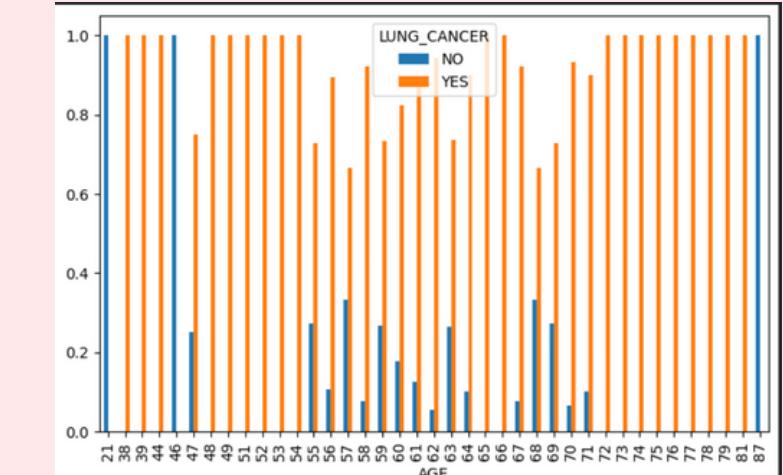
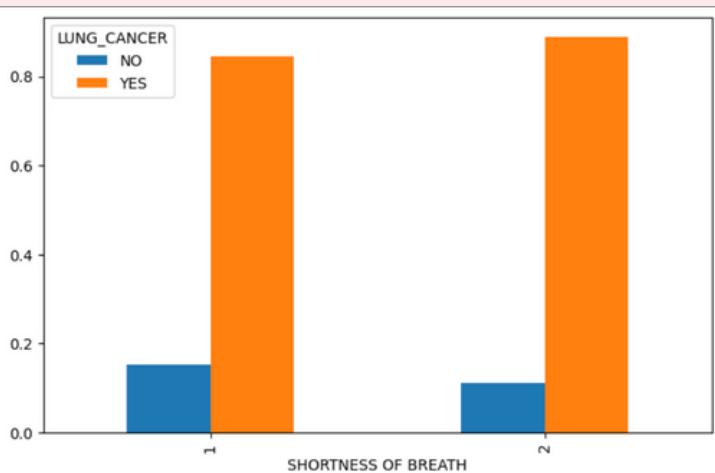
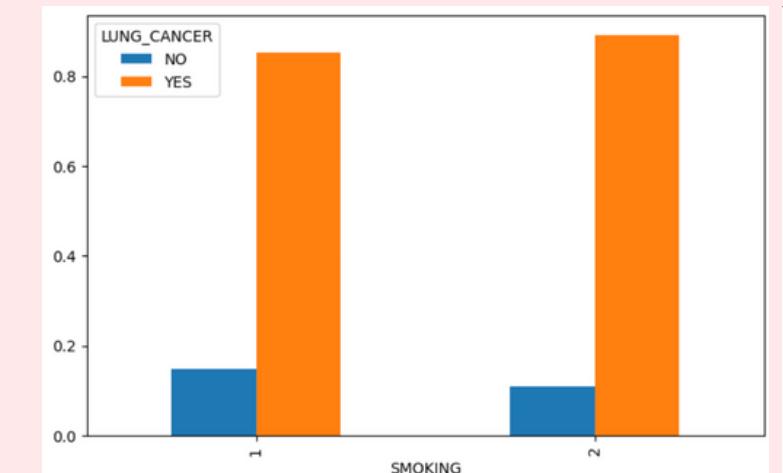
```
#Removing Duplicates  
df=df.drop_duplicates()
```

```
df.shape  
(276, 16)
```

Label Encoder tiap Fitur

No = 0  
Yes = 1

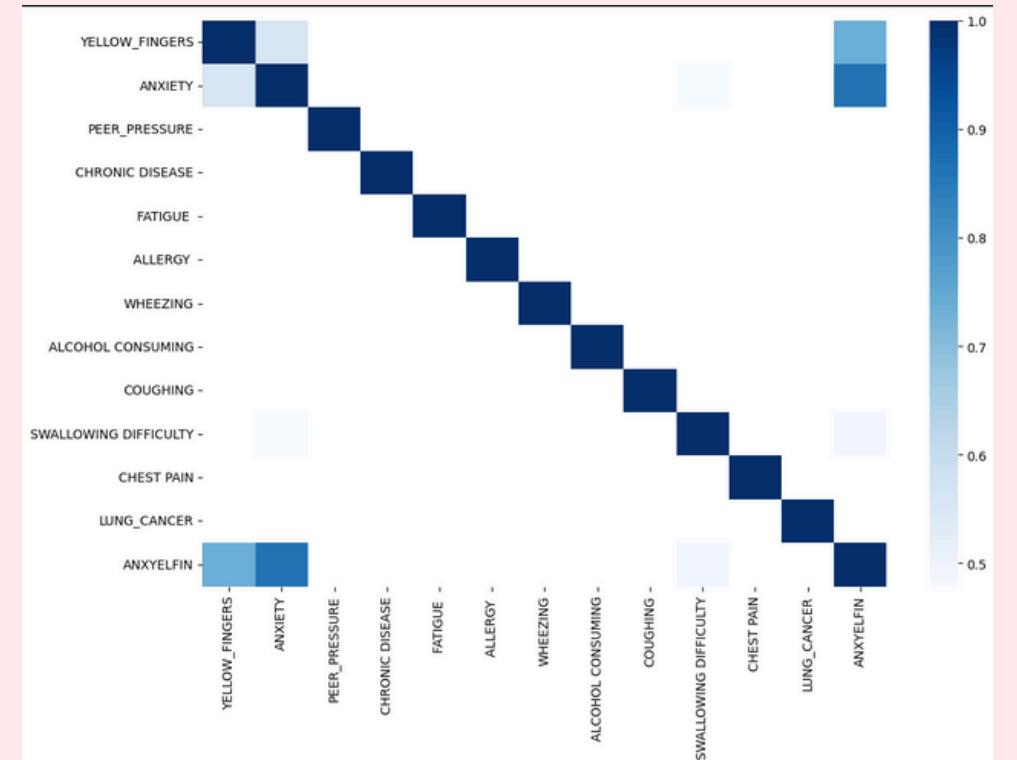
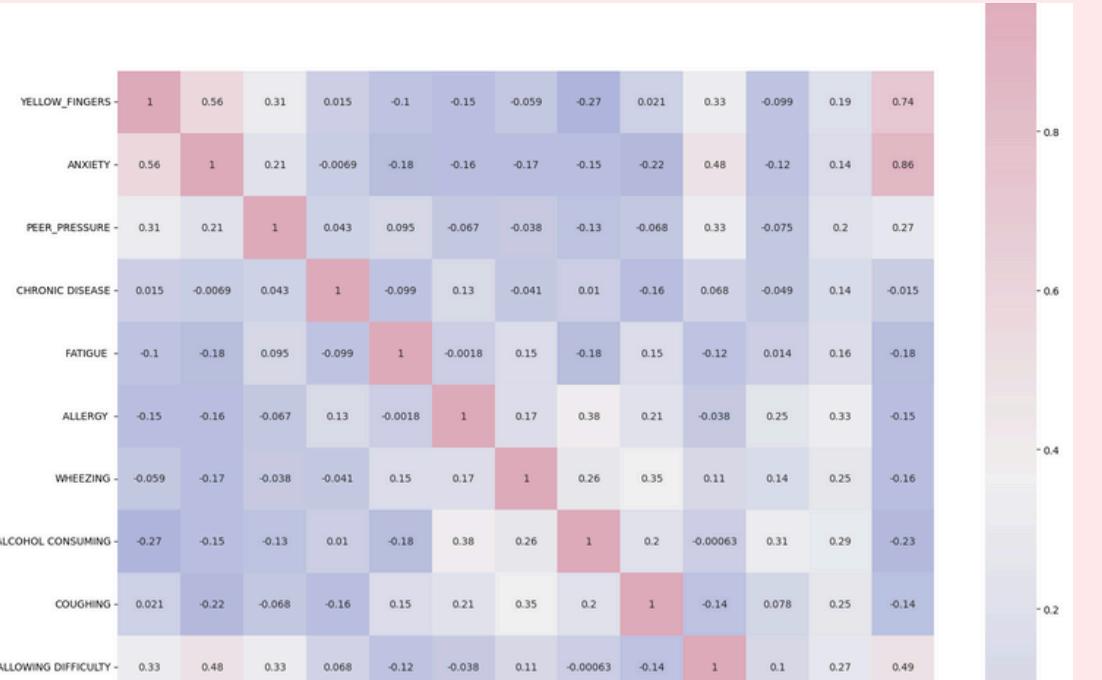
Drop kolom yang tidak punya daya pembeda



GENDER, AGE, SMOKING, SHORTNESS OF BREATH

# Data Preprocessing

## Melihat Correlation



Anxiety dan Yellow Fingger memiliki korelasi lebih dari 50%, jadi buat fitur baru dengan kombinasi itu

## Target distribution imbalance handling

```
from imblearn.over_sampling import ADASYN  
adasyn = ADASYN(random_state=42)  
X, y = adasyn.fit_resample(X, y)
```

```
len(X)
```

```
477
```

## Splitting Data

# Modelling (Logistic Regression)

Model Logistic Regression bekerja sangat baik pada dataset ini:

- Precision dan recall tinggi untuk kedua kelas
- Sangat akurat mendeteksi pasien kanker
- Tidak terlalu bias karena imbalance sudah ditangani
- Performa stabil dengan accuracy 97%, macro avg 0.97

Model ini layak dijadikan baseline atau bahkan model utama jika interpretabilitas (mudah dijelaskan) adalah prioritas.

## Classification Report LR

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.96      | 1.00   | 0.98     | 64      |
| 1            | 1.00      | 0.95   | 0.97     | 56      |
| accuracy     |           |        | 0.97     | 120     |
| macro avg    | 0.98      | 0.97   | 0.97     | 120     |
| weighted avg | 0.98      | 0.97   | 0.97     | 120     |

# Modelling (K Nearest Neighbor)

Model KNN menunjukkan performa yang sangat baik pada dataset ini:

- Precision dan recall sama-sama tinggi untuk kedua kelas
- Akurat mendeteksi pasien kanker paru-paru, dengan hanya sedikit kasus yang terlewat
- Tidak terlalu bias, karena imbalance sudah ditangani dengan ADASYN
- Akurasi stabil di 96%, dengan macro average precision/recall/F1 sekitar 0.96

Secara keseluruhan, model KNN sangat cocok untuk dataset kecil seperti ini, dan dapat digunakan sebagai model alternatif yang kuat selain Logistic Regression atau Random Forest.

## Classification Report KNN

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.93      | 1.00   | 0.96     | 64      |
| 1            | 1.00      | 0.91   | 0.95     | 56      |
| accuracy     |           |        | 0.96     | 120     |
| macro avg    | 0.96      | 0.96   | 0.96     | 120     |
| weighted avg | 0.96      | 0.96   | 0.96     | 120     |

# Modelling (Random Forest)

Model Random Forest memberikan performa yang sangat tinggi pada dataset lung cancer ini:

- Precision dan recall sama-sama sangat tinggi (0.98) untuk kedua kelas, menunjukkan kemampuan model yang konsisten dalam mendeteksi pasien kanker maupun non-kanker
- Akurasi model mencapai 98%, menjadi salah satu yang tertinggi di antara semua model yang diuji
- Model tidak bias, karena performanya seimbang pada kedua kelas setelah imbalance ditangani dengan ADASYN
- F1-score 0.98 menunjukkan bahwa model mampu menangkap pola dengan sangat baik tanpa overfitting

Secara keseluruhan, RF adalah model terbaik untuk dataset ini, dan sangat cocok digunakan jika tujuan utama adalah akurasinya setinggi mungkin, bukan interpretabilitas.

## Classification Report RF

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.98      | 0.98   | 0.98     | 64      |
| 1            | 0.98      | 0.98   | 0.98     | 56      |
| accuracy     |           |        | 0.98     | 120     |
| macro avg    | 0.98      | 0.98   | 0.98     | 120     |
| weighted avg | 0.98      | 0.98   | 0.98     | 120     |

# Modelling (XGBoost)

Model XGBoost menghasilkan performa yang sangat tinggi pada dataset ini:

- Precision, recall, dan F1-score rata-rata 0.97–0.98
- Akurasi model stabil di 97%
- Mampu mendeteksi pasien kanker dengan sangat baik, hanya sedikit kesalahan klasifikasi
- Tidak bias terhadap salah satu kelas karena imbalance sudah ditangani dengan ADASYN
- Lebih robust dibanding model simpel seperti Logistic Regression dan tidak mudah overfit

## Classification Report XGBoost

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.98      | 0.97   | 0.98     | 64      |
| 1            | 0.96      | 0.98   | 0.97     | 56      |
| accuracy     |           |        | 0.97     | 120     |
| macro avg    | 0.97      | 0.98   | 0.97     | 120     |
| weighted avg | 0.98      | 0.97   | 0.98     | 120     |

# Cross Validation

## K-Fold Cross Validation

```
Logistic regression models' average accuracy: 0.9371323529411766  
KNN models' average accuracy: 0.9286589635854343  
Random forest models' average accuracy: 0.9580182072829132  
XGBoost models' average accuracy: 0.9496848739495799
```

Hasil K-Fold Cross Validation menunjukkan bahwa model Random Forest memiliki akurasi tertinggi sebesar 95.6%, diikuti oleh XGBoost yang menghasilkan akurasi hampir sama. Sementara itu, model KNN memiliki akurasi terendah yaitu 92.8%.

## Stratified K-Fold cross-validation

```
Logistic regression models' average accuracy: 0.9350315126050421  
KNN models' average accuracy: 0.9224264705882352  
Random forest models' average accuracy: 0.9434348739495799  
XGBoost models' average accuracy: 0.9309173669467787
```

Hasil Stratified K-Fold Cross Validation menunjukkan bahwa model Random Forest memiliki akurasi tertinggi sebesar 94.6%. Model lainnya juga menunjukkan akurasi yang hampir sama 92-93%

## SOLUTION OVERVIEW



# Project Summary

Pada project ini, saya membuat model machine learning untuk memprediksi risiko kanker paru-paru berdasarkan data gejala dan kebiasaan hidup. Setelah melakukan EDA dan memilih fitur yang benar-benar berpengaruh, saya menangani ketidakseimbangan data dengan ADASYN agar model lebih akurat. Saya mencoba beberapa model seperti Logistic Regression, KNN, Random Forest, dan XGBoost. Hasilnya semua model mencapai akurasi tinggi (96–98%), dengan Random Forest dan XGBoost sebagai yang paling konsisten. Secara keseluruhan, model yang dibangun dapat membantu mendeteksi potensi kanker paru-paru lebih cepat dan akurat.

## CHALLENGES FACED

### Challenge 1

#### Data Imbalance pada Label Kanker

Jumlah pasien dengan label “kanker” dan “tidak kanker” tidak seimbang. Hal ini membuat model awal cenderung bias dan sulit mendekripsi kelas minoritas. Untuk mengatasinya, saya menggunakan ADASYN agar data lebih seimbang dan model bisa belajar dengan lebih akurat.

### Challenge 2

#### Menentukan Fitur yang Benar-Benar Relevan

Beberapa fitur awal seperti gender, age, dan smoking ternyata tidak menunjukkan hubungan kuat dengan label kanker berdasarkan EDA. Tantangannya adalah memilih fitur mana yang sebaiknya dipertahankan atau dibuang agar model lebih bersih, sederhana, dan tidak terdistraksi oleh fitur yang tidak relevan.

# What I Learned

## Personal Skills Gained

Dari project lung cancer prediction ini, saya belajar bagaimana menangani dataset yang tidak seimbang menggunakan ADASYN agar model tidak bias ke salah satu kelas. Saya juga memahami pentingnya memilih fitur yang benar-benar relevan, karena fitur seperti age, gender, atau smoking ternyata tidak memiliki korelasi kuat dengan label kanker. Selain itu, saya belajar membandingkan beberapa algoritma seperti Logistic Regression, KNN, Random Forest, dan XGBoost, serta menggunakan K-Fold dan Stratified K-Fold Cross Validation untuk memastikan model yang saya pilih stabil dan konsisten. Secara keseluruhan, project ini membantu saya lebih memahami proses end-to-end dalam membangun model klasifikasi medis yang akurat dan dapat dipercaya.

KEYLA'S PROJECT

# The End

NAME

Keyla Faristha Rindani